

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

ZÍSKAVANIE ŠTRUKTÚROVANÝCH DÁT
O PACIENTOCH S OCHORENÍM COVID-19
Z PREPÚŠŤACÍCH SPRÁV A KRVNÝCH
VÝSLEDKOV
BAKALÁRSKA PRÁCA

2023
MARIÁN KRAVEC

UNIVERZITA KOMENSKÉHO V BRATISLAVE
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

ZÍSKAVANIE ŠTRUKTÚROVANÝCH DÁT
O PACIENTOCH S OCHORENÍM COVID-19
Z PREPÚŠŤACÍCH SPRÁV A KRVNÝCH
VÝSLEDKOV
BAKALÁRSKA PRÁCA

Študijný program: Dátová veda
Študijný odbor: Informatika a Matematika
Školiace pracovisko: Katedra aplikovanej informatiky
Školiteľ: Mgr. Vladimír Boža, PhD.

Bratislava, 2023
Marián Kravec



Univerzita Komenského v Bratislave
Fakulta matematiky, fyziky a informatiky

ZADANIE ZÁVEREČNEJ PRÁCE

Meno a priezvisko študenta: Marián Kravec
Študijný program: dátová veda (Medziodborové štúdium, bakalársky I. st., denná forma)
Študijné odbory: informatika
matematika
Typ záverečnej práce: bakalárska
Jazyk záverečnej práce: slovenský
Sekundárny jazyk: anglický

Názov: Získavanie štruktúrovaných dát o pacientoch s ochorením COVID-19 z prepúšťacích správ a krvných výsledkov
Extracting structured data about patients with COVID-19 from discharge reports and blood results

Anotácia: Nemocničný informačný systém v Univerzitnej nemocnici v Bratislava obsahuje iba neštruktúrované textové dáta o pacientoch (či už prepúšťaciu správu alebo výsledky krvných testov).

Takýto formát dát neumožňuje efektívnu analýzu dát a hľadanie faktorov, ktoré ovplyvňujú prognózu liečby Covid-19.

Cieľom práce je vytvoriť softvér, ktorý tieto neštruktúrované dáta premení do tabuľkovej podoby, ktoré sa dajú následne jednoducho analyzovať.

Vedúci: Mgr. Vladimír Boža, PhD.
Katedra: FMFI.KAI - Katedra aplikovanej informatiky
Vedúci katedry: prof. Ing. Igor Farkaš, Dr.
Dátum zadania: 20.10.2022

Dátum schválenia: 22.10.2022

doc. Mgr. Tomáš Vinař, PhD.
garant študijného programu

študent

vedúci práce

Pod'akovanie: Touto cestou by som rád poďakoval svojmu školiťovi Mgr. Vladimírovi Božovi, Phd. za ochotu a rady pri písaní práce a kódu. Zároveň by som rád poďakoval pánovi doc. MUDr. Petrovi Sabakovi, PhD. za umožnenie použitia kódu vyvinutého počas projektu na účely tejto práce.

Abstrakt

Nemocničný informačný systém v Univerzitnej nemocnici v Bratislava neumožňuje lekárovi získať štrukturalizované dáta o jednom pacientovi respektíve o množine pacientov rýchlo a jednoducho, preto sme vytvorili systém ktorého úlohou je získavania požadovaných z prepúšťacích správ a krvných výsledkov vďaka čomu sa práca lekára výrazne skrátila a zjednodušila. Systém je nastavený na získavanie dát informácii o pacientoch hospitalizovaných s ochorením COVID-19 avšak je ho možné pomerne jednoducho upraviť pre získavanie inej množiny dát.

Kľúčové slová: prepúšťacia správa, regulárny výraz, tretie

Abstract

Hospital information system in University Teaching Hospital in Bratislava does not allow the doctor to obtain structured data about one patient or a group of patients quickly and easily, therefore we have created a system whose task is to obtain the required informations from discharge reports and blood results, thanks to which the doctor's work has been significantly shortened and simplified. The system is set up for obtaining data on patients hospitalized with the disease of COVID-19, but it can be modified relatively easily to obtain another set of data.

Keywords: discharge report, regular expresion

Obsah

Úvod	1
1 Podobné práce	3
2 Štruktúra prepúšťacej správy	7
2.1 Zdroj dát	7
2.2 Výzor vstupných dát	7
2.2.1 Blok A - Osobné údaje a obdobie hospitalizácie	7
2.2.2 Blok B - Anamnéza	8
2.2.3 Blok C - Vyšetrenia	8
2.2.4 Blok D - Terapia	8
2.2.5 Blok E - Epikríza	9
2.2.6 Blok F - Záver, odporúčania, špecifické nálezy	9
2.2.7 Blok G - Krvné výsledky	9
2.3 Problémy pri rozdelení dát na bloky	9
2.3.1 Problém nenájdenných blokov	9
2.3.2 Problém nesprávne umiestnených dát	10
2.4 Riešenia problémov s rozdelením dát do blokov	10
2.4.1 Homogénny text	10
2.4.2 Menej väčších blokov	10
2.5 Predspracované dáta	11
3 Získavanie dát	13
3.1 Všeobecný postup	13
3.2 Osobné údaje pacienta a obdobie hospitalizácie	14
3.3 JIS a smrť	15
3.4 Výška a váha	15
3.5 Saturácia krvi kyslíkom pri prijatí	16
3.6 Protilátky proti vírusu SARS-CoV-2 pri prijatí	17
3.7 Oxygenoterapia	19
3.8 Lieky	20

3.9	Choroby pacienta	20
3.10	Krvné výsledky	21
3.11	Chýbajúce časti vstupu	22
3.12	Výstupné súbory	23
4	Analýza výsledkov a chýb	25
4.1	Validačné dáta	25
4.2	Časová náročnosť	26
4.3	Chybovosť jednotlivých skupín získavaných	26
4.3.1	Osobné údaje pacienta a obdobie hospitalizácie	26
4.3.2	JIS a smrť	27
4.3.3	Výška a váha	27
4.3.4	Saturácia krvi kyslíkom pri prijatí	27
4.3.5	Protilátky proti vírusu SARS-CoV-2 pri prijatí	27
4.3.6	Oxygenoterapia	27
4.3.7	Lieky	27
4.3.8	Choroby pacienta	27
4.3.9	Krvné výsledky	27
5	Využitie v praxi	29
6	Modifikácia a vylepšenia	31
	Záver	33
	Príloha A	37
	Príloha B	39

Zoznam obrázkov

2.1	Rozloženie správy	8
2.2	Upravené rozloženie správy	11
3.1	Hlavička a)	14
3.2	Hlavička b)	14
3.3	Protilátky	17
3.4	Protilátky zvýraznené	18
3.5	Logovací súbor	23

Úvod

V nemocničnom informačnom systéme Univerzitnej nemocnice v Bratislave nie je možnosť jednoducho získať tabuľku obsahujúcu dáta jedného pacienta respektíve skupiny pacientov, tieto dát sa získavali ručne buď postupným kopírovaním jednotlivých dát nachádzajúcich sa v rôznych častiach informačného systému alebo ich hľadaním a následným prepisovaním z prepúšťacej správy.

Tento proces bolo potrebné opakovať pre každého jedného pacienta čo bolo časovo náročné a vyžadovalo si nezanedbateľné množstvo ľudskej práce.

Hlavným účelom tejto práce je vytvorenie softvéru, ktorý pomôže výrazne zrýchliť a zjednodušiť získavanie týchto dát.

Tento softvér na svojom vstupe dostane prepúšťaciu správu pacienta a jeho krvné výsledky v podobe klasického textu a následne z týchto ne-štrukturalizovaných dát získava jednotlivé požadované dáta pričom v prípade, že nejakú informáciu nenájde alebo zistí, že zistená hodnota nie je v očakávaných limitoch alebo, že sa v správe nachádza viacero hodnôt pre jednu informáciu tak užívateľovi oznámi o akú informáciu ide a aký je s ňou problém.

Práca je rozdelená do piatich kapitol. V prvá obsahuje informácie o podobných softvéroch. Druhá kapitola sa zameriava na štruktúru prepúšťacej správy a dáta ktoré sa z nej snažíme získať. Tretia kapitola obsahuje problémy ktoré sa objavili pre jednotlivé získavané informácie a aké spôsoby riešenia sme sa rozhodli použiť. V štvrtej je analýza chybovosti softvéru. Posledná kapitola je o modifikáciách softvéru aby bol jednoduchšie použiteľný a modifikovateľný pre iné podobné použitia.

Na účely domácej úlohy 2 sú určené strany 3 až 11. $p = \min(1, e^{-\frac{\Delta E}{t}})$

Kapitola 1

Podobné práce

Aj napriek moderným nemocničným informačným systémom je stále veľké množstvo nemocničných záznamov v podobe čistého alebo čiastočne štrukturovaného textu z ktorého je ručné získavanie dát časovo náročné. Preto sa na to využívajú automatizované systémy ktoré zväčša fungujú na jednom z dvoch princípov, respektíve na kombinácii oboch. Tými prístupmi sú regulárne výrazy a metódy strojového učenia určené na spracovanie prirodzeného jazyka.

Metóda regulárnych výrazov využíva na hľadanie informácii v texte špeciálne kódované reťazce znakov ktoré slúžia ako vzor. V texte sa hľadajú miesta, ktoré sa zhodujú so vzorom a z nájdených miest sa následne vyberá získavaná informácia.

Metóda strojového učenia...

Obe tieto prístupy majú svoje výhody a nevýhody [1]. Výhodou regulárnych výrazov je ich presnosť a transparentnosť čiže možnosť vidieť a upravovať vnútorné fungovanie programu, presnejšie možnosť upravovať jednotlivé regulárne výrazy hľadajúce konkrétne informácie. Medzi nevýhody tohto prístupu patrí napríklad fakt, že všetky regulárne výrazy ktoré softvér využíva treba ručne vytvárať a vylepšovať čo je často náročné, väčšinou sú špecifické pre určitú oblasť pre ktorú je softvér vytváraný čo komplikuje využívanie regulárnych výrazov ktorých správne fungovanie bolo už otestované v iných softvéroch. Ďalšou nevýhodou je, že v prípade komplikovaných výrazov je aj ich upravovanie a vylepšovanie komplikované. Na druhej strane v prípade použitia niektorej z metód strojového učenia je často možné využiť už existujúcu metódu spracúvajúcu prirodzený jazyk a modifikovať ju pre konkrétne použitie a natrénovať model na predpripravených dátach, avšak aj tento prístup má nevýhody ako napríklad, že natrénovaný model často nie sú až tak presný ako dobre nastavené regulárne výrazy, pre zvýšenie presnosti je často nutné zväčšiť množstvo ručne spracovať dát určených na tréning modelu a zároveň v prípade nájdenia častej chyby alebo nutnosti modifikácie hľadaných dát (pridanie alebo odobranie získavanej informácie) je nutné model upraviť a celý nanovo pretrénovať a validovať aj už skôr validované časti.

Medzi už existujúce systémy využívajúce regulárne výrazy patrí napríklad systém HEDEA, [2] čiže Healthcare Data Extraction and Analysis ktorého autormi sú Anshul Aggarwal, Sunita Garhwal a Ajay Kumar a bol vyvinutý na získavanie Indických medicínskych dát. Systém využitím regulárnych výrazov hľadá každú jednu získavanú informáciu tak, že hľadá v texte kľúčové slovo označujúce požadovanú informáciu, následne ak by mala k danej informácii existovať aj konkrétna hodnota (či už číselná alebo slovná) tak hľadá túto hodnotu v okolí kľúčového slova a následne túto informáciu aj s jej hodnotou zapíše do databázy k konkrétnemu pacientovi na základe jeho identifikačného čísla ktoré sa na každom spracovávanom texte musí nachádzať. Podobne ako v našom prípade je hlavnou úlohou tohto softvéru získavať medicínske dáta z čiastočne štrukturalizovaných vstupných dát čiže lekárskeho správ a výsledkov testov. Hlavné rozdiely oproti nášmu systému sú, že systém HEDEA sa snaží získavať iba základné dáta o pacientovi ako sú osobné údaje, výška, váha, tlak, základné krvné výsledky a prekonané ochorenia inými slovami jeho účelom je vytvoriť databázu obsahujúcu anamnézy jednotlivých pacientov ktorú môže využiť lekár pri diagnostike daného pacienta zatiaľ čo my získavame okrem týchto dát aj dáta špecifické pre pacientov s ochorením COVID-19 ako napríklad typ oxygenoterapie alebo výsledky testov na protilátky proti vírusu SARS-CoV-2 a našou snahou je vytvoriť tabuľku s dátami o ochorení COVID-19 ktorá sa dá využiť na analýzu rizikových faktorov a liečby tohto ochorenia, zároveň systém HEDEA určený na spracovávanie Indických dát takže je vytvorený pre dáta písané v oficiálnom jazyku Indie v tomto prípade angličtinu zatiaľ čo náš model je vytvorený pre dáta v slovenčine.

Systémom využívajúcim metódu strojového učenia na spracovávanie prirodzeného jazyka je napríklad systém ktorý vytvorili Fette a kol. na Univerzite vo Würzburgu [3] ktorý využívajúci metódu učenia s učiteľom s názvom Conditional random field ktorej úlohou je označiť jednotlivé slová respektíve viacslovné pomenovania [4] a následne pomocou metódy Keyword Matching with Terminology based disambiguation prepojiť nájdené slová a viacslovné pomenovania s databázou odborných pojmov tak, že v prípade jednoznačného prepojenia považuje danú informáciu za klasifikovanú a v prípade nejednoznačného prepojenia (dané slovo môže byť časťou rôznych informácií napríklad v prípade číselnej hodnoty nevieme bez ďalšej informácie určiť k čomu patrí) hľadá v okolí označeného slova iné označené slovo s jednoznačným prepojením ktoré bližšie určí prepojenie nejednoznačného slova. Okrem samotného spôsobu získavania dát je v porovnaní s našim systémom rozdiel aj v prioritách pri získavaní dát keďže náš systém je vytvorený na čo najväčšiu presnosť pri získavaní dát špecificky z prepúšťacích správ zatiaľ čo ich systém je vytvorený tak aby ho bolo možné byť natrénovaný na získavanie dát z rôznych typov medicínskych dokumentov či už lekárskeho správ, výsledkov testov alebo klinických štúdií pričom jedinou podmienkou je aby sa všetky získavané údaje nachádzali v databáze odborných pojmov a takisto platí, že celý systém je vytvorený

pre iný jazyk ako náš systém v tomto prípade ide o nemčinu.

Prístup ktorý kombinuje metódu strojového učenia s regulárnymi výrazmi využili v svojom systéme Cui a kol. [5] ktorý využili metódu s názvom Constructive heuristic ktorej úlohou nebolo priamo hľadanie získavaných informácií v texte ale generovanie čo najlepších regulárnych výrazov na to určených. Tento algoritmus začína s prázdnu množinou regulárnych výrazov a následne iteratívne túto množinu rozširuje a upravuje kým nie je splnená ukončovacia podmienka [6]. Výhodou tohto prístupu oproti bežným metódam strojového učenia je, že na konci tréningu má užívateľ množinu regulárnych výrazov ktoré môže ďalej upravovať a nie "čiernu skrinku" ako v prípade bežnej metódy strojového učenia, ktorej vnútornému fungovaniu je pre človeka nepochopiteľné. Oproti len použitiu regulárnych výrazov má výhodu, že nie je nutné regulárne výrazy vymýšľať od začiatku ale stačí iba výstup mierne upraviť. Nevýhodou je, že pochopenie a upravenie regulárnych výrazov je síce možné ale môže to byť pomerne náročné keďže ide o počítačom generované regulárne výrazy ktoré aj napriek tomu, že fungujú rovnako dobre môžu sa výrazne líšiť od toho čo by napísal človek. Hlavným rozdielom oproti nášmu systému je to, že hlavnou úlohou ich systém nie je priame získavanie dát z medicínskej dokumentácie ale generovanie regulárnych výrazov ktoré je po na takýto problém možné použiť.

Kapitola 2

Štruktúra prepúšťacej správy

Táto kapitola sa zameriava na pochopenie vstupných dát a približnú lokalizáciu hľadanych informácií v nich.

2.1 Zdroj dát

Prepúšťacie správy a krvné výsledky ktoré náš systém spracováva sú správami pacientov ktorý boli v období od marca roku 2020 do decembra roku 2021 hospitalizovaný na klinike infektológie a geografickej medicíny univerzitnej nemocnice v Bratislave.

2.2 Výzor vstupných dát

Dáta z ktorých sa snažíme získať informácie o pacientovi softvér dostáva v tvare textu obsahujúceho prepúšťaciu správu a krvné výsledky. Väčšina textu v prepúšťacej správe nie je generovaná automaticky nemocničným informačným systémom ale je písaná lekárom čo spôsobuje, že každá správa je do určitej miery originálna.

Napriek tomu existuje základná štruktúra ktorú majú spoločnú takmer všetky prepúšťacie správy vďaka ktorej je možné túto správu rozdeliť do blokov (viď obrázok 2.1) ktoré obsahujú určitý informácie. Teraz si prejdeme, čo obsahujú jednotlivé bloky a čo z nich sa mi snažíme získať.

2.2.1 Blok A - Osobné údaje a obdobie hospitalizácie

Bloku A je dvojriadková hlavička v ktorej sa nachádzajú osobné údaje pacienta, čiže jeho celé meno a rodné číslo, a zároveň sa tam nachádza dátum prijatia a dátum prepustenia daného pacienta. Všetky tieto informácie sa snažíme získať.



Obr. 2.1: Rozdelenie správy do špecifických blokov podľa ich obsahu

2.2.2 Blok B - Anamnéza

Tento blok obsahuje informácie o anamnéze a stave pacienta pri prijatí do nemocnice, z tohto bloku sa snažíme získavať informácie ako sú výška, váha a saturácia krvi kyslíkom pri prijatí, a informácia o dlhodobých alebo v minulosti prekonaných chorobách a problémoch ako sú cukrovka, astma, demencia, infarkt myokardu, artérová hypertenzia, fibrilácia predsiení, srdcové zlyhanie a ďalšie.

2.2.3 Blok C - Vyšetrenia

Blok C obsahuje informácie o vykonaných vyšetreniach, pre nás sú podstatné výsledky testov na protilátky proti vírusu SARS-CoV-2 typu IgG a IgM pri prijatí, prípadne výsledok testu na ochorenie CDI (Infekcia spôsobená *Clostridium difficile*).

Zároveň sa tu nachádzajú aj výsledky krvných testov avšak tie sa tu nemusia nachádzať úplné. Preto softvér ktorým to spracovávame ich považuje za kontrolné a samotné informácie o krvných výsledkoch sa získavajú z posledného bloku (2.2.7).

2.2.4 Blok D - Terapia

V tomto bloku sú informácie o terapii odtiaľto získavame informáciu o liekoch ktoré boli pacientovi podané počas hospitalizácie a o tom či pacient potreboval aj oxygenoterapia a v prípade, že áno aj o aký typ oxygenoterapie išlo.

2.2.5 Blok E - Epikríza

Tento blok obsahuje časť správy s názvom epikríza čiže záverečná, súhrnná správa o pacientovi, priebehu jeho choroby a hospitalizácie. Jedinou získavanou informáciou je informácie o smrti pacienta. Táto časť sa však dá zároveň využiť aj na prípadnú kontrolu iných získavaných informácií keďže môže obsahovať informáciu o iných ochoreniach pacienta, jeho liečbe, prípadne o prítomnosti protilátok proti vírusu SARS-CoV-2.

2.2.6 Blok F - Záver, odporúčania, špecifické nálezy

Blok F obsahuje zvyšné časti správy ako sú záver, odporúčania a špecifické nálezy. Avšak obsah tohto bloku je výrazne nekonzistentný a jeho jednotlivé časti nemusia byť vôbec prítomné v správe. Našťastie tento blok by nemal neobsahovať žiadne konkrétne získavané informácie.

2.2.7 Blok G - Krvné výsledky

Záverečný blok už nie je priamo prepúšťacia správa ale ide o krvné výsledky pacienta ktoré narozdiel od výsledkov v bloku C (2.2.3) sa tu nachádzajú úplné a zároveň vďaka tomu, že nie sú napísané vedľa seba ako v bloku C ale pod sebou (každý výsledok na samostatnom riadku) je práca s nimi výrazne jednoduchšia.

2.3 Problémy pri rozdelení dát na bloky

Pri snahe o implementáciu tohto delenia sme zistili, že aj napriek tomu, že sa pomerne veľký počet správ dal do takýchto blokov rozdeliť, tak sa objavilo niekoľko problémov či už pri samotnom delení správy ako aj pri informačnom obsahu jednotlivých častí kvôli ktorým sa ukazuje vhodnejšie takéto riešenie vôbec nepoužiť alebo použiť nejakú robustnejšiu verziu tohto delenia. Niektoré z nájdených problémov si teraz opíšeme.

2.3.1 Problém nenájdenej blokov

Pri kontrole správ rozdelených do blokov sme zistili, že sa občas stávalo, že náš softvér nebol schopný nájsť niektorý z blokov, väčšinu z týchto problémov vieme rozdeliť do troch skupín: chýbajúci alebo nesprávne ohraničený blok F, blok E skrytý v bloku F, chýbajúci alebo nesprávne napísaný začiatok bloku.

Prvý problém pre nás nepredstavuje veľký problém keďže v bloku F by sa nemali nenachádzať hľadané informácie.

Druhý problém je o niečo horší keďže blok E je pre nás dôležitý ale tento problém bolo jednoduché opraviť tým, že ak softvér nenájde blok E pri prvotnom delení správy

ešte skontroluje či sa v bloku F náhodnou nenachádza.

Tretí problém sa ukazuje ako najproblematickejší sa ukázalo ako pomerne komplikované určiť začiatok a koniec bloku ak softvér nenájde kľúčové slová ktorými sa vo väčšine prípadov jednotlivé bloky začínajú a preto sa stávalo, že softvér niektoré bloky nenašiel a lebo ich pripojil k iným blokom. Tento problém sa stal jedným z hlavných zmeny prístupu k dátam.

2.3.2 Problém nesprávne umiestnených dát

Ako ďalší veľký problém sa ukazuje to, že niektoré informácie sa nenachádzajú sa očakávanom mieste. Zväčša išlo o informácie o anamnéze pacienta a výsledkoch jeho vyšetrení ktoré sme predpokladali, že nájdeme v blokoch B respektíve C avšak časť týchto informácií sa nachádzala až v bloku F.

Tento problém samotný sa dá riešiť tým, že informácie ktoré hľadáme v blokoch B a C budeme nakoniec hľadať avšak tento problém spôsobuje, že problém ktorý máme s nájdením a správnym ohraničením bloku F sa stáva relevantným a treba ho riešiť, nanešťastie tento problém je podobný problému ohraničeniu ostatných blokov a preto je jeho riešenie pomerne komplikované.

2.4 Riešenia problémov s rozdelením dát do blokov

Skúšaním rôznych spôsobov riešenia sa ukázalo, že najvhodnejšie je neriešiť okrajové prípady súčasného rozdelenia správy ale prerobiť samotné rozdeľovanie. Našli sme najlepšie spôsoby...


2.4.1 Homogénny text

Jednou možnosťou je považovať celý text ako jeden homogénny text v ktorom hľadáme všetky informácie.

Tento prístup rieši všetky naše problémy avšak zbytočne hľadá niektoré informácie aj na miestach kde vieme, že sa nikdy nebudú nachádzať čo ho spomaľuje.

2.4.2 Menej väčších blokov

Tento prístup využíva rozdelenie do blokov ale namiesto pôvodných 7 blokov toto nové rozdelenie má iba 3 bloky, vďaka čomu nemusí hľadať všetky informácie v celom texte a zároveň pri správnom rozdelení vyriešime problémy ktoré sa v pôvodnom rozdelení objavili.



Obr. 2.2: Upravené rozdelenie správy do menšieho počtu väčších blokov

Výzor nového rozdelenia môžeme vidieť na obrázku 2.2. Vidíme, že jediná zmena ktorá nastala je taká, že sme bloky B až F spojili do jedného bloku s názvom B a pôvodný blok G sme premenovali na blok C.

Toto rozdelenie rieši všetky vyššie spomenuté problémy vďaka tomu, že o bloku A vieme, že vždy bude mať tvar dvojriadkovej hlavičky s pri skúšaní sme nenašli žiadnu výnimku, podobne pôvodný blok G čiže nový blok C nie je súčasťou samotnej prepúšťacej správy ale sú to krvné výsledky pacienta ktoré sú v našom vstupe vždy až za správou a majú tvar dvojíc testovaná veličina a výsledok testu (pozitivita alebo hodnota) vďaka čomu je jednoduché ich oddeliť od textu správy. Samotný text správy sa problematické pre ďalšie delenie preto ho nechávame pokope v bloku B.

2.5 Predspracované dáta

Na účely kontroly či náš systém funguje správne sme mali v dispozícii aj niekoľko desiatok predspracovaných pacientov, čiže pacientov u ktorých sme mali ich prepúšťaciu správu a krvné výsledky a zároveň sme poznali získavané informácie.

Problémom týchto dát však bolo, že často boli pre konkrétneho pacienta buď nekompletné alebo obsahovali informáciu ktorá sa nenachádzala ani v správe ani v krvných výsledkoch alebo boli nesprávne čo bolo spôsobené tým, že tieto dáta boli získavané iným spôsobom konkrétne tak, že poverená osoba dostala prístup do nemocničného informačného systému z ktorého následne jednotlivé dáta získavala. Konkrétne problém chýbajúcich dát boli často spôsobené tým, že v čase spracovávania pacienta daný

pacient ešte nebol prepustený z nemocnice, v prípade problému dát nenachádzajúcich sa v prepúšťacej správe a krvných výsledkov išlo o prípady kedy lekár túto informáciu do prepúšťacej správy nedal a v prípade nesprávnych údajov išlo s väčšou o ľudskú chybu keďže tieto dáta boli získavané ručne.

Kapitola 3

Získavanie dát

V tejto kapitole si povieme niečo o tom ako sme postupovali pri získavaní dát všeobecne a následne si prejdeme k jednotlivým získavaným dátam ich špecifiká a problémy ktoré sa pri ich získavaní vyskytli a ako sme tieto problémy riešili. Keďže však viaceré dáta majú veľmi podobný až totožný spôsob získavania rozhodli sme sa ich utriediť do skupín dát ktoré majú spolu súvis a majú rovnaký spôsob získavania.

3.1 Všeobecný postup

Vo všeobecnosti bol postup pri získavaní jednotlivých údajov nasledovný:

1. Výber "trénovacej" množiny dát
2. Zistenie najbežnejších spôsobov zápisu daného údaje
3. Vytvorenie jednoduchých regulárnych výrazov schopných nájsť požadovanú informáciu
4. Pokus o získavanie informácie z dát
5. Kontrola výsledkov, identifikácia problémových miest
6. Modifikácia regulárnych výrazov, eliminácia chybových výsledkov
7. Opakovanie krokov 4 až 6 kým sa v "trénovacej" množine dát vyskytujú chyby
8. Výber "kontrolnej" množiny dát
9. Pokus o získavanie informácie z dát
10. Kontrola výsledkov, identifikácia problémových miest
11. V prípade, že sa chyby nevyskytnú považujeme, naše regulárne za správne, v opačnom prípade považujeme našu "kontrolnú" množinu dát za tréningovú a opakujeme postup od kroku 4

Meno	RČ	Dátum prijatia	Dátum prepustenia
Priezvisko Meno	XXXXXX/XXXX	DD.MM.YYYY	DD.MM.YY

Obr. 3.1: Výzor hlavička pacienta ktorý nebol preložený na JIS

Meno	RČ	Dátum prijatia	Dátum prepustenia	
Priezvisko Meno	XXXXXX/XXXX	DD.MM.YYYY	DD.MM.YY preklad	DD.MM.YY

Obr. 3.2: Výzor hlavička pacienta ktorý bol preložený na JIS

3.2 Osobné údaje pacienta a obdobie hospitalizácie

Ako prvé boli získavané dáta nachádzajúce sa v hlavičke dokumentu konkrétne išlo o meno pacienta, jeho rodné číslo dátumy prijatia a prepustenia. Zároveň sa v tejto časti dopočítavali 2 hodnoty a to vek pacienta a dĺžka hospitalizácie.

Hlavička má výzor tabuľky s dvomi riadkami a štyrmi alebo piatimi stĺpcami v závislosti od toho či bol pacient počas hospitalizácie preložený z infekčného oddelenia na jednotku intenzívnej starostlivosti (JIS) respektíve na iného oddelenie alebo nie. Konkrétne v prípade ak pacient nebol preložený na iné oddelenie počas hospitalizácie hlavička vyzerá ako na obrázku 3.1 a v prípade, že preložený bol tak vyzerá takto ako na obrázku 3.2.

Softvér z tejto tabuľky vyberie hodnoty z druhého riadka pričom v prípade, že v štvrtom stĺpci nájde informáciu o preklade na iné oddelenie tak dátum v tomto stĺpci ignoruje a za dátum prepustenia považuje dátum v piatom stĺpci.

Dátumy prijatia a prepustenia sú následne pre-typované do podoby časovej značky čím sa zároveň skontroluje platnosť dátumu (či taký dátum môže existovať) v prípade, že pri niektorom z dátumov vyskytne problém je táto informácia zapísaná do logovacieho súboru. V prípade, že sú obe dátumy v poriadku je následne spravený ich rozdiel čím sa vypočíta dĺžka hospitalizácie, čiže počet dní medzi prijatím a prepustením pričom tento výsledok nám dáva ďalšiu kontrolu dátumov keďže očakávame, že dĺžka hospitalizácie je kladné číslo avšak nepredpokladáme, že to číslo bude veľmi veľké, konkrétne pri testovaní sa ukázalo, že priemerná dĺžka hospitalizácie je približne 12 dní pričom štandardná odchýlka je približne 9 dní avšak občas sa objavia aj prípady ktorých dĺžka hospitalizácie je cez 50 dní pričom nenastal žiaden preklep pri zapisovaní dátumom preto sme sa rozhodli použiť ako hornú hranicu hodnotu 100 ktorá pokrývala všetky naše doterajšie prípady.

Nakoniec v prípade, že dátum prijatia je v poriadku tak softvér určí z rodného čísla dátum narodenia a pomocou dátumu narodenia a dátumu prijatia vypočíta vek pacienta pri prijatí. Tento vek následne kontroluje či je v intervale 0 až 120, v prípade,

že do tohto intervalu nepatrí indikuje to chyba buď v dátume prijatia alebo v rodnom čísle pacienta.

3.3 JIS a smrť

Keďže naše dáta sú prepúšťacie správy iba z infekčného oddelenia tak nevieme čo sa s pacientom dialo po opustení oddelenia avšak to čo nás zaujíma je, že dôvod opustenia oddelenia konkrétne to čo nás zaujíma je, že či sa mu stav zhoršil na toľko, že musel byť preložený na jednotku intenzívnej starostlivosti respektíve či dôvodom na opustenie oddelenia nebolo úmrtie pacienta.

V prípade preloženia na JIS je táto informácia v časti "Epikríza" (2.2.5) pričom je väčšinou zapísaná ako "prekladáme na JIS" respektíve "prekladáme na jednotku intenzívnej starostlivosti" pričom avšak keďže sa táto informácia do epikrízy píše iba v prípade, že preklad uskutočnil tak sa ukázalo, že je vhodnejšie v nej hľadať iba informáciu "JIS" respektíve "jednotka intenzívnej starostlivosti" keďže pri hľadaní aj informácie "prekladáme na" sa vyskytlo viac prípadov keď mal systém problém túto informáciu odhaliť z dôvodu rôzneho skloňovania a gramatických chýb.

V prípade smrti pacienta sa na koniec epikrízy napíše informácia "exitus lethalis". Avšak ukázalo sa, že nie vždy sa táto informácia v správe nachádza aj napriek tomu, že smrť nastal čo je spôsobené tým, že smrť nastala na jednotke intenzívnej starostlivosti alebo sa na ňu z nejakého dôvodu zabudlo preto sa po komunikácii s pánom doktorom Sabakom rozhodlo, že v prípade, že bol pacient preložený na jednotku intenzívnej starostlivosti alebo bol pripojený na umelú pľúcnu ventiláciu a v správe sa nenachádza informácia o smrti tak sa táto situácia zaznamená do logovacieho súboru aby to mohol užívateľ správnosti informácie skontrolovať.

3.4 Výška a váha

Ďalšie informácie ktoré sa o pacientovi získavali boli jeho výška a váha, pričom následne bola z týchto hodnôt ešte počítaná hodnota BMI. Ukazuje sa, že existuje viacero spôsobov akými lekári zapisujú túto informáciu do správy pričom našou snahou je aby náš systém zvládol nachádzať túto informáciu pri všetkých možnostiach zápisu. Tieto spôsoby sú nasledovné:

- [výška/váha/hmotnosť] [hodnota][cm/kg] (názov a hodnota)
- [hodnota][cm/kg],[hodnota][cm/kg] (hodnoty oddelene čiarkou)
- [hodnota][cm/kg]/[hodnota][cm/kg] (hodnoty oddelene medzerou)

- [hodnota][cm/kg] [hodnota][cm/kg] (hodnoty oddelene lomkou)

Systém kontroluje prítomnosť každej z týchto možností v texte správy a v prípade nájdenie zhody túto informáciu následne čistí rozdelením v prípade ak sa jedná o dve hodnoty oddelené nejakým deličom a následným odstránením všetkých nepodstatných informácií tak aby nakoniec ostali iba číselné informácie pričom však systém si stále pamätá ktorá hodnota prislúcha ktorej informácii (či ide o výšku alebo váhu). Následne je táto číselná hodnota kontrolovaná či je v "rozumnom" intervale pričom pre výšku je využívaný interval 20-250 cm a pre váhu je interval 10-300 kg ak sa nájde hodnota ktorá nepatrí do týchto intervalov je to považované za možnú chybu a informácia o tom je zapísaná do logovacieho súboru, takisto za chybu sa považuje aj prípad ak systém nedokázal nájsť niektorú z týchto informácií v texte.

V prípade nájdenia oboch informácií (aj výšky aj váhy) je z týchto hodnôt počítaná hodnota BMI pričom tak ako predchádzajúce hodnoty aj táto je kontrolovaná či sa nachádza v "rozumnom" intervale 10-60, vďaka tejto kontrole vieme zachytiť aj chyby s výškou a váhou ktoré nie sú evidentné z jednotlivých informácií, medzi takéto prípady patria napríklad chyby ako vymenenie hodnôt výšky a váhy lekárom (príklad z textu správy "výška/váha: 75cm/150kg") alebo možná chyba v niektorom údajov (príklad z textu správy "výška/váha: 103cm/90kg"), samozrejme ani v jednom prípade si nemôžeme byť istí či chyba naozaj nastala a aká konkrétne je a preto v takýchto prípadoch údaje považujeme za priebežne správne a do logovacieho súboru dávame informáciu užívateľovi aby správnosť údajov skontroloval.

3.5 Saturácia krvi kyslíkom pri prijatí

Jednou z ďalších informácií ktorá nás zaujímala bola saturácia krvi kyslíkom. Táto informácia bola pre nás zaujímavá keďže sa jedná o pacientom s ochorením COVID-19 ktoré sa zväčša prejavuje ako respiračné ochorenie a saturácia krvi kyslíkom je zaujímavý ukazovateľ stavu pacienta. Konkrétne nás zaujímala táto hodnota pri prijatí aby sme mali predstavu v akom stave bol pacient hospitalizovaný.

Pri hľadaní sme postupovali tak, že sme hľadali kľúčové slovo respektíve skratku (konkrétne sa jednalo o slová "SpO2" alebo "SatO2" a ich varianty) nasledované číselnou hodnotou pričom občas sa stávalo, že medzi hľadaným slovom a hodnotou sa nachádzala ešte informácia "bez kyslíka" označujúca, že bola meraná pred podaním oxygenoterapie pacientovi.

V prípade, že systém našiel v texte viackrát zapísanú informáciu o saturácii krvi kyslíkom tak za správnu považoval tú ktorá sa nachádza v texte najskôr keďže sa informácia pri prijatí zväčša píše do časti "Anamnéza" (2.2.2) ktorá sa nachádza na začiatku správy.

rýchlotest SARS-CoV-2: protilátky IgM: POZIT, IgG: POZIT			
S-anti-SARS-CoV-2 IgM (ELISA)/1.12.2020/	55,5	NTU	pozitívny
S-anti-SARS-CoV-2 IgG (ELISA)/1.12.2020/	34,7	NTU	pozitívny
09.12.2020- PROTILÁTKY SARS - CoV - 2: IgM: POZIT IgG: POZIT			
Rýchlotest na vyšetrenie protilátok proti SARS2-COV: IgM silno pozit, IgG slabo pozit			
16.3.2021 Protilátky SARS-CoV-2: IgM:pozit., IgG: pozit			
Rýchlotest na protilátky SARS CoV-12: IgM slabo pozit. IgG negat.			
Protilátky COVID 19 rýchlotest z kapilárnej krvi: IgG: POZIT IgM: NEGAT			
Rýchlotest na protilátky SARS-CoV2 (z kapilárnej krvi): IgM pozitívne, IgG pozitívne			
PROTILÁTKY SARS - CoV - 2:/5.1.21/.:IgM: POZIT,IgG: POZIT			
Protilátky na SARS-Cov-2: 29.12. IgM, IgG negat., 5.1.21 IgM,IgG pozit.			

Obr. 3.3: Rôzne spôsoby zápisu testov na protilátky v prepúšťacích správach

Občas sa objavila situácia, že hodnota nebolo jedno číslo ale bol to interval (príklad z textu správy "SatO2: 90-93%"). V takomto prípade sme sa rozhodli považovať za skutočnú hodnotu dolnú hranicu tohto intervalu.

V prípade nenájdenia žiadnej hodnoty je informácia o tom zapísaná do logovacieho súboru.

3.6 Protilátky proti vírusu SARS-CoV-2 pri prijatí

Keďže náš systém analyzuje prepúšťacie správy pacientov s ochorením COVID-19 tak jednou z pre nás veľmi zaujímavých informácií je výsledok testu na protilátky proti tomuto ochoreniu. Pri hľadania výsledkov testov na protilátky sa ukázalo, že každý lekár ich zapisuje iným spôsobom pričom aj v správach jedného lekára sa nachádzajú rozdiel medzi jednotlivými zápsmi. Niekoľko konkrétnych ukážok je na obrázku 3.3.

Pri hľadaní a následnom získavaní informácie sme využili fakt, že všetky spôsoby zápisu týchto testov obsahujú rovnaké respektíve podobné kľúčové slová a pre nás dôležitú informáciu v rovnakom poradí konkrétne vždy prvým kľúčovým slovom je názov vírusu alebo názov choroby v našom prípade je to vírus SARS-CoV-2 respektíve v niektorých prípadoch ochorenie COVID-19, následne ide kombinácia typov protilátok, konkrétne IgG a IgM, a samotných výsledkov testov. Ukážka zvýraznenia hľadaných slov je na obrázku 3.4.

Systém najskôr nájde celé úryvky textu obsahujúce testy následne z týchto úryvkov odstráni všetky slová a znaky ktoré sú pre samotný výsledok nepodstatné ako napríklad slová "slabo", "silno" alebo "rýchlotest". Keďže systém nájde iba špecificky testy na protilátky proti SARS-CoV-2 je pre nás v nájdenom úryvku nepodstatná táto informácia. Nakoniec nám ostanú iba názvy protilátok a výsledky pričom sa ukazuje, že vyskytujú v dvoch formách a to dvojice protilátka a výsledok alebo ako jeden spoločný výsledok

rýchlotest SARS-CoV-2: protilátky IgM: POZIT, IgG: POZIT

S-anti-SARS-CoV-2 IgM (ELISA)/1.12.2020/ 55,5 NTU pozitívny

S-anti-SARS-CoV-2 IgG (ELISA)/1.12.2020/ 34,7 NTU pozitívny

09.12.2020- PROTILÁTKY SARS - CoV - 2: IgM: POZIT IgG: POZIT

Rýchlotest na vyšetrenie protilátok proti SARS2-COV: IgM silno pozit, IgG slabo pozit

16.3.2021 Protilátky SARS-CoV-2: IgM: pozit., IgG: pozit

Rýchlotest na protilátky SARS CoV-12: IgM slabo pozit. IgG negat.

Protilátky COVID 19 rýchlotest z kapilárnej krvi: IgG: POZIT IgM: NEGAT

Rýchlotest na protilátky SARS-CoV2 (z kapilárnej krvi): IgM pozitívne, IgG pozitívne

PROTILÁTKY SARS - CoV - 2: /5.1.21/: IgM: POZIT, IgG: POZIT

Protilátky na SARS-CoV-2: 29.12. IgM, IgG negat., 5.1.21 IgM, IgG pozit.

Obr. 3.4: Zvýraznené hľadania informácie v rôznych spôsoboch zápisu testov na protilátky

Tabuľka 3.1: Rozhodnutia systém pri rôznych poradiach názvov testov a ich výsledkov

Poradie častí	Rozhodnutie
[protilátka] [výsledok] [protilátka] [výsledok]	názov protilátky pred výsledkom
[protilátka] [protilátka] [výsledok]	názov protilátky pred výsledkom
[výsledok] [protilátka] [výsledok] [protilátka]	názov protilátky za výsledkom
[výsledok] [protilátka] [protilátka]	názov protilátky za výsledkom
[protilátka] [výsledok] [protilátka]	problém (systém všeobecne považuje za názov protilátky pred výsledkom s chýbajúcim výsledkom)
[výsledok] [protilátka] [výsledok]	problém (systém všeobecne považuje za názov protilátky pred výsledkom s chýbajúcim názvom protilátky)

pre obe protilátky. V testovaných prípadoch sa vždy vyskytol názov protilátky pred výsledkom testu avšak nakoniec sme sa rozhodli spraviť systém všeobecnejší tým, že prípadov keď je výsledok za názvom testu je schopný správne rozlíšiť a spracovať aj prípady keď je poradie opačné. Konkrétne v prípade nájde iba jeden názov protilátky (obrázok 3.4 druhý príklad) a iba jeden výsledok poradie je jasne určené, v ostatných prípadoch sa rozhoduje podľa tabuľky 3.1.

V prípade, že sa v správe nachádza viacero testov na protilátky proti vírusu SARS-CoV-2 zaujíma nás ten najstarší. Pôvodne bola snaha využiť dátumy avšak ukázalo sa, že veľkom počte prípadov informácia o dátume testovania chýba preto sme sa rozhodli tento postup nevyužiť. Ďalším pokusom bola heuristická úvaha, že čím skôr je test v správe tým je starší, táto heuristika však vykazovala príliš vysokú chybovosť preto sme ani ju nevyužili. Nakoniec sme sa po debate s pánom doktorom Sabakom

rozhodli využiť heuristickú úvahu, ktorá hovorí, že ak existuje test na určitú protilátku s negatívnym výsledkom tak aj najstarší test bude mať negatívny výsledok a naopak ak test s negatívnym výsledkom neexistuje (a existujú s pozitívnym výsledkom) tak aj najstarší je má pozitívny výsledok. Táto heuristika sa opiera o výsledky štúdie ktorá ukázala, že test na protilátky typu IgM je pozitívny aj po viac ako 60 dňoch od nástupu príznakov a v prípade protilátok typu IgG je to až 90 dní [7]. Keďže bola väčšina pacientov hospitalizovaná výrazne kratšie obdobie ako 60 dní tak nepredpokladáme, že by počas hospitalizácie nastala situácia, že pacientovi vyjde negatívny výsledok testu aj napriek pozitívite predchádzajúceho. Zároveň sa ukazuje, že ak pacientovi vyjde pozitívny test na obe protilátky už ďalší test na protilátky nie je vykonaný keďže ani lekár zväčša nepredpokladá, že by množstvo protilátok v krvi počas hospitalizácie výrazne kleslo.

3.7 Oxygenoterapia

V prípade oxygenoterapie sme zo správy získavali dve informácie a to či bola pacientovi podaná oxygenoterapia a ak bola určiť o aký typ oxygenoterapie išlo. Konkrétne rozlišujeme tri základné typy a low-flow, HFNO (high-flow nasal oxygenotherapy) a UPV (umelú pľúcnu ventiláciu).

V prípade, že systém nenašiel žiadnu informáciu (žiadne kľúčové slová) o podaní oxygenoterapie zapísal si k pacientovi informáciu "bez oxygenoterapie" v opačnom prípade sa typ určí na základe toho aké kľúčové slová boli v texte nájdené. Konkrétne systém nájdené slová vyhodnocuje nasledovne:

- "low flow", "low-flow" a podobne - low-flow
- "high flow", "high-flow", "HFNO" a podobne - HFNO
- "umelá pľúcna ventilácia", "UPV" a podobne - UPV

V prípade, ak sa v texte nachádza informácie aj o low-flow aj o HFNO alebo UPV tak je informácia o low-flow zanedbaná keďže ide o menej "extrémny" typ. Avšak v prípade ak sa v správe nachádza informácia aj o HFNO aj o UPV sú do výslednej informácie o pacientovi zapísané obe a to v tvare "HFNO/UPV". Ak v správe nebol typ oxygenoterapie presne určený ale nachádzala sa tam iba informácie o spôsobe podania ako "maska" alebo "nosová kanyla" je to považované za low-flow oxygenoterapiu pričom do výslednej informácie o pacientovi je to zapísané ako "low-flow (neupresnené)" aby bolo jasne označené, že konkrétna informácia o typu nie je v správe prítomná.

3.8 Lieky

Získavanie informácie sa ukázalo ako veľmi priamočiare keďže našou snahou nebolo získať množinu liekov ktorú pacient dostával ale mali sme množinu liekov a zisťovali sme ktoré z nich pacient dostával. Dôvodom pre tento prístup bol fakt, že pacienti často dostávali lieky a vitamíny určené na liečby iných problémov ktorými títo pacienti trpeli a pre nás bola dôležitá len množina liekov ktoré mohli byť použité na liečbu ochorenia COVID-19. Konkrétne išlo o tieto lieky: Dexametazon, Remdesivir, Olumiant, Favipiravir, Ivermectin a Colchicin.

Konkrétne hľadanie týchto liekov bolo zisťovanie či sa názov lieku nachádza v správe, zo začiatku sme skúšali hľadanie iba v časti "Terapia" (2.2.4) avšak nakoniec sme sa rozhodli hľadať v celej správe aby sme predišli prípadom keď v správe je informácia o danej liečbe ale táto informácia sa už nedostala do terapie a takisto sme chceli zachytiť prípady kedy išlo o samoliečbu pacienta respektíve lieky predpísané obvodným lekárom ktoré už ale po hospitalizácii neužíval (hlavne v prípade lieku Ivermectin). Keďže sa nenašli prípady kedy by lekár do správy zapísal informáciu o lieku ktorý pacient neužíval tak sa tento spôsob hľadania informácie o týchto liekoch ukázal ako najspoľahlivejší.

Boli aj snahy zistiť okrem samotných liekov aj informáciu o počte dní počas ktorých boli tieto lieky pacient užíval a dávku lieku ktorá mu bola predpísaná avšak sa ukázalo, že vo výraznej väčšine správ buď táto informácia úplne chýba alebo je neúplná a tieto informácie z nej nie je možné získať preto nakoniec padlo rozhodnutie nezískavať tieto informácie.

3.9 Choroby pacienta

Keďže pri ochorení COVID-19 tak ako aj pri iných ochoreniach sa niektoré iné diagnózy považujú za rizikové faktory. Preto aj našou snahou bolo sa pokúsiť získať informáciu či pacient niektorou z diagnóz považovaných za možné rizikové faktory trpí respektíve ju prekonal. Našťastie pre nás sa táto informácia často nachádza v časti "Anamnéza" (2.2.2) avšak môže sa objaviť aj iných častiach správy keďže k danému problému môže dôjsť aj počas hospitalizácie.

Konkrétne diagnózy ktorých prítomnosť alebo prekonanie u pacienta sa snažíme určiť sú následovné: cukrovka, artériová hypertenzia, srdcové zlyhanie, infarkt myokardu, fibrilácia predsiení, periférne artériové ochorenie dolných končatín, chronická obštrukčná choroba pľúc, astma, cievna mozgová príhoda, demencia, sepsa a kolitída. Pričom v prípade ochorenia sepsa a kolitída nás nezaujíma či ich pacient v minulosti prekonal ale či sa vyskytli pri prijatí alebo počas hospitalizácie.

V prípade väčšiny týchto chorôb je ich získavanie priamočiare, konkrétne sa jedná

o zisťovanie či sa v texte správy nachádza informácia o tejto chorobe u pacienta či už vo forme celého názvu (pri niektorých chorobách niektorého z viacerých používaných názvov napríklad cukrovka a diabetes alebo periférne artériové ochorenie dolných končatín a ateroskleróza) alebo vo forme skratky (napríklad CHOCHP pre chronická obštrukčná choroba pľúc alebo IM pre infarkt myokardu). Tento postup sa ukázal ako vhodný aj pre sepsu keďže prekonanie tejto choroby sa nezapisuje do anamnézy a v anamnéze respektíve v správe sa vyskytuje iba v prípade ak ňou pacient trpí pri alebo počas hospitalizácie.

Špecifické bolo určovanie kolitídy pri alebo počas hospitalizácie. V tomto prípade sa ukázal problém, že veľmi často informácia, že sa v správe nachádza názov tohto ochorenia neznamena automaticky prítomnosť tohto ochorenia u pacienta ale môže ísť o negatívny výsledok testu na toto ochorenie alebo prípad, že toto ochorenie bolo pacientom prekonané v minulosti. Konkrétny prístup ktorý sme sa rozhodli použiť pre čo najlepšie určenia prítomnosti tohto ochorenia u pacienta je tvorený dvomi časťami. Najskôr prebehne kontrola či sa v správe nachádza hociká informácie o tomto ochorení čiže či sa tam nachádza názov (kolitída alebo *clostridium difficile*) alebo skratka (CDI) tejto choroby, v prípade ak sa v správe nenachádza žiadna informácia tak to systém považuje za prípad keď pacient na kolitídu počas hospitalizácie netrpel. Ak sa nejaká informácia o tomto ochorení v správe nachádza nasleduje druhá časť hľadania kedy hľadáme informáciu o teste na toto ochorenie, konkrétny spôsob hľadania a vyhodnocovania testov na toto ochorenie je podobný ako zisťovanie výsledkov testov na protilátky proti vírusu SARS-CoV-2 (3.6) s rozdielom, že namiesto SARS-CoV-2 hľadáme *clostridium difficile* a keďže ide o test na prítomnosť protilátok ale baktérie nás netrápi typ (pri SARS-CoV-2 sme rozlišovali IgG a IgM protilátky). V prípade ak sa nájde pozitívny test tak tvrdíme, že pacient počas hospitalizácie na toto ochorenie trpel, naopak v prípade, že všetky nájdené testy sú negatívne tak tvrdíme, že pacient netrpel na toto ochorenie počas hospitalizácie, špeciálny prípad je ak systém nenájde žiaden test na toto ochorenie v takom prípade systém nevie určiť správny výsledok a preto zapíše informáciu o tomto probléme do logovacieho súboru aby to mohol užívateľ skontrolovať.

3.10 Krvné výsledky

Záverečná ale najväčšia skupina informácii ktoré sme získavali boli niektoré výsledky krvných testov. Nie su pre nás dôležité všetky výsledky ale iba určitá vybraná podmnožina konkrétne ide o výsledky ktoré sa v laboratórnych výsledkoch označujú nasledujúcimi skratkami: CRP, PCT, S_D3, GLU, KREA, ALT, GMT, FERR, TnT, NEU#, LYM#, EO#, PLT, CD4A, CD8A, INR, FBG, DD.

Hľadanie týchto výsledkov by sa dalo rozdeliť na dve časti a to hlavné hľadanie a doplnkové hľadanie. V prípade hlavného hľadania sú tieto údaje hľadané časti správy "Krvné výsledky" (2.2.7). Konkrétne hľadá informácie v tvare "[názov]: [hodnota]" pričom následne z toho získame samotnú číselnú hodnotu. Priebežne si zapamätáva aj informáciu ktoré údaje nenašiel, v tomto prípade chýbajúci údaj nie je nutne chybou keďže nie každému pacientovi boli robené rovnako komplexné krvné testy. Po pokuse o získania všetkých údajov nastáva druhá časť ktorou je doplnkové hľadanie v tejto časti sa údaje ktoré sa nepodarilo nájsť v časti "Krvné výsledky" hľadajú v texte samotnej prepúšťacej správy. Hlavným dôvodom pre toto hľadanie boli prípady kedy či už z nejakého dôvodu sme nedostali úplné krvné výsledky alebo bolo počas hospitalizácie robených viacero nezávislých krvných testov pričom my sme dostali iba niektoré ale výsledky týchto testov boli zapísané do správy. Tieto dáta sa nachádzajú v správe v časti "Vyšetrenia" (2.2.3) avšak ako bolo aj pri popise výzoru vstupných dát vysvetlené v tejto časti sa často nachádza iba nejaký výber výsledkov ktorý nemusí obsahovať tie ktoré my potrebujeme. Problém ktorý sa objavuje v tejto časti je fakt, že pre určitý údaj sa v správe môže nachádzať viacero hodnôt keďže ten istý test bol počas hospitalizácie spravený pacientovi niekoľkokrát v takom prípade je informácia zapísaná v tvare "[názov]: [hodnota 1]; [hodnota 2]; ... [hodnota n]," pričom v takom prípade my berieme prvú hodnotu keďže tieto hodnoty sú usporiadané v poradí v akom boli testy robené (časovo) a nás zaujíma hodnota najbližšie k začiatku hospitalizácie keďže chceme vedieť v akom stave bol pacient na začiatku nemocničnej liečby.

V prípade, že ani hlavné, ani doplnkové hľadanie nenájde nejaké výsledky testov je informácie o ich nenájdenej zapísaná do logovacieho súboru avšak keďže táto informácia sa nemusí nutne v správe nachádzať nie je táto informácia zapísaná medzi chyby ktoré sa pri získavaní informácii objavili ale je samostatne označená ako nenájdene výsledky testov. V prípade, že sa pri doplnkovom hľadaní zistí, že sa výsledok testu objavuje v správe viackrát pričom sú pri ňom odlišné hodnoty je to považované za chybu a informácia o tejto chybe je zapísaná do logovacieho súboru.

3.11 Chýbajúce časti vstupu

Vo väčšine prípadov je výzor našich presne taký ako je popísaný v kapitole "Štruktúra prepúšťacej správy" (2) avšak občas sa objavil problém neúplnosti dát. Konkrétne išlo o prípady kedy sa vo vstupnom texte nenachádzali výsledky krvných testov, v takom prípade jediná zmena ktorú systém spraví je, že pri získavaní údajov z krvných výsledkoch preskočí hlavné hľadanie (keďže nemá na to potrebný text) a údaje získava iba pomocou doplnkového hľadania v texte prepúšťacej správy. Občas sa objavili ešte extrémnejší prípad kedy sme pre dané pacienta dostali iba hlavička (2.2.1) a informácia

Pacient z hárku [číslo hárku v ktorom sa nachádza daná správa]:
Meno pacienta: [priezvisko a meno pacienta]
Problémové udaje: [názvy údajov ktoré boli počas získavania označené za problémové]
Nenajdene výsledky: [názvy krvných výsledkov ktoré sa v správe nepodarilo nájsť]

Obr. 3.5: Výzor zápisu informácie o chýbajúcich a problémových údajoch v logovacom súbore pre jedného pacienta

”chýba správa” v takomto prípade sa zo získavania dát vykoná iba získavanie osobných údajov pacienta a obdobia jeho hospitalizácie (3.2) aby bola zachovaná existencia tohto pacienta a logovacieho súboru sa zapisuje informácia o chýbajúcej správe.

3.12 Výstupné súbory

Výsledkom celého získavania informácie zo vstupných dát je dvojica súborov, ide o súbor vo formáte XLSX ktorý je možné otvoriť v programe Microsoft Excel a obsahuje tabuľku v ktorej jednotlivé riadky sú pacienti a stĺpce sú jednotlivé získavané údaje, druhým súborom je textový logovací súbor obsahujúci pre každého spracovávaného pacienta v tvare zobrazenom na obrázku 3.5.

Kapitola 4

Analýza výsledkov a chýb

Táto kapitola je zameraná na analýzu presnosti a chybovosti nášho systému.

4.1 Validačné dáta

Z dôvodu malého množstva predspracovaných dát a problémoch s nimi popísaných v časti 2.5 sme sa rozhodli, že na účely validácia výsledkov nášho systému ručne pracujeme dáta o 100 pacientoch ktorý neboli použitý pri vytváraní regulárnych výrazov.

Konkrétny postup ktorý sme zvolili bol následovný:

1. Príprava súboru obsahujúceho vstupné informácie o 100 pacientoch
2. Ručné spracovanie pacientov
3. Spracovanie pacientov využitím nášho systému
4. Vytvorenie kópie systémom spracovaných pacientov
5. Vylepšenie systémom spracovaných pacientov pomocou logovacieho súboru
6. Porovnanie ručne získaných dát s dátami získanými pomocou nášho systému pôvodnými aj vylepšenými
7. Určenie chybovosti nášho systému

Keďže naše "validačné" dáta boli získavané ručne nemáme istotu, že sú bezchybné, preto sme sa pre účely určenia chybovosti systému rozhodli každý údaj ktorý je totožný s údajom získaným našim systémom považovať za správny a každý údaj ktorý sa líši skontrolujeme aby sme určili či je to chybou nášho systému alebo či ide o ľudskú chybu.

4.2 Časová náročnosť

Každý zo spôsobov spracovania pacientov bol rôzne časovo náročný, v prípade ručného spracovania trvalo spracovanie jedného pacienta približne 5 minút, čiže spracovanie 100 pacientov trvalo okolo 500 minút čiže viac ako 8 hodín. Náš systém dokázal spracovať 100 pacientov za menej ako minútu konkrétne priemerný čas ktorý na 100 pacientov potreboval bol 40 sekúnd, následné ručné vylepšenie pomocou logovacieho súboru trvalo pri 100 pacientoch približne 30 minút.

4.3 Chybovosť jednotlivých skupín získavaných

Z dôvodu, že náročnosť získavania nie je rovnaká pre všetky získavané dáta ani chybovosť nie je rovnaká preto si najskôr prejdeme chybovosť nášho systému pre jednotlivé skupiny získavaných dát (skupiny sú rovnaké ako v kapitole 3).

4.3.1 Osobné údaje pacienta a obdobie hospitalizácie

V prípade údajov ako je meno a priezvisko pacienta jeho rodné číslo a dátumy prijatia a prepustenia sa neobjavila žiadna chyba. V prípade dĺžky hospitalizácie sa objavili 2 nezrovnalosti avšak ukázalo sa, že išlo o chyby pri ručnom spracovaní a systém vypočítal správne hodnoty. Pri informácii o veku pacienta sa objavilo pomerne veľké množstvo nezrovnalosti konkrétne 22 pričom toto bolo spôsobené tým, že pri ručnom získavaní bola využitá hodnota veku ktorú lekár napísal do správy a v prípade nášho systému bol vek vypočítaný na základe rodného čísla a dátumu prepustenia. Presnejšie išlo o to, že lekár s najväčšou pravdepodobnosťou počítal vek iba na základe roku narodenia a z tohto dôvodu do správy napísal vyšší vek aj napriek tomu, že pacient ešte v danom roku nemal narodeniny.

Kontrola s logovacím súborom nepriniesla žiadne zlepšenie. Pri získavaní týchto informácií vykazuje náš systém nulovú chybovosť.

4.3.2 JIS a smrt

4.3.3 Výška a váha

4.3.4 Saturácia krvi kyslíkom pri prijatí

4.3.5 Protilátky proti vírusu SARS-CoV-2 pri prijatí

4.3.6 Oxygenoterapia

4.3.7 Lieky

4.3.8 Choroby pacienta

4.3.9 Krvné výsledky

Kapitola 5

Využitie v praxi

Táto kapitola hovorí o odbornom článku v ktorom boli využívané dáta získané z pre-púšťacích správ a krvných výsledkov pacientov našim softvérom.

Kapitola 6

Modifikácia a vylepšenia

Obsahom tejto kapitole sú úpravy a vylepšenia softvéru tak aby bol jednoduchší na používanie pre používateľa a aby ho bolo možné jednoducho modifikovať pre získavanie dát zo správ pacientov s iným ochorením ako je COVID-19 respektíve pre získavanie všeobecných informácii nachádzajúcich sa každej prepúšťacej správe.

Záver

Toto má ešte čas.

Literatúra

- [1] Roni Romano, Lior Rokach, and Oded Maimon. Cascaded data mining methods for text understanding, with medical case study. In *Sixth IEEE International Conference on Data Mining-Workshops (ICDMW'06)*, pages 458–462. IEEE, 2006.
- [2] Anshul Aggarwal, Sunita Garhwal, and Ajay Kumar. Hede: a python tool for extracting and analysing semi-structured information from medical records. *Healthcare informatics research*, 24(2):148–153, 2018.
- [3] Georg Fette, Maximilian Ertl, Anja Wörner, Peter Kluegl, Stefan Störk, and Frank Puppe. Information extraction from unstructured electronic health records and integration into a data warehouse. In *GI-Jahrestagung*, pages 1237–1251, 2012.
- [4] Hanna M Wallach. Conditional random fields: An introduction. *Technical Reports (CIS)*, page 22, 2004.
- [5] Menglin Cui, Ruibin Bai, Zheng Lu, Xiang Li, Uwe Aickelin, and Peiming Ge. Regular expression based medical text classification using constructive heuristic approach. *IEEE Access*, 7:147892–147904, 2019.
- [6] Constructive heuristic. in wikipedia, the free encyclopedia. <http://en.wikipedia.org/w/index.php?title=Constructive%20heuristic&oldid=1032227019>, 2022. [Online; accessed 07-December-2022].
- [7] Rachel West, Amanda Kobokovich, Nancy Connell, and Gigi Kwik Gronvall. Covid-19 antibody tests: a valuable public health tool with limited relevance to individuals. *Trends in microbiology*, 29(3):214–223, 2021.

Príloha A: obsah elektronickej prílohy

Príloha B: Používateľská príručka